Извештај за Домашна Задача 3

Систем за предвидување на дијабетес во реално време со Apache Spark и Kafka

1. Опис на проектот

Целта на овој проект е да се изгради комплетен систем за обработка на податоци (Data Pipeline) кој се состои од две фази: **Offline фаза** за тренирање на модел за машинско учење и **Online фаза** за предвидување на дијабетес во реално време користејќи стриминг податоци.

---

2. Подготовка на податоците

Податоците се преземени од *Diabetes Health Indicators Dataset*. За потребите на задачата, оригиналното множество е поделено на две датотеки:

- **offline.csv**: Се користи за тренирање и евалуација на моделите.
- **online.csv**: Се користи за симулација на стриминг податоци во реално време преку Kafka.

---

3. Offline фаза (Машинско учење)

Во оваа фаза, во рамките на Apache Spark апликација, се извршени следните чекори:

- **Трансформации**: Дефиниран е метод за обработка кој користи `VectorAssembler` за спојување на карактеристиките во вектор и `StandardScaler` за нормализација на податоците.
- **Тренирање**: Тестирани се 3 класификациски модели со користење на `CrossValidator` и `ParamGridBuilder`:
    1. **Logistic Regression**
    2. **Random Forest Classifier**
    3. **Decision Tree Classifier**
- **Евалуација**: Моделите беа евалуирани според **F1 метриката**.
- **Серијализација**: Најдобриот модел е зачуван локално во директориумот `saved_models/best_diabetes_model` како `PipelineModel` за да може да се вчита во online фазата со веќе дефинираните трансформации.

---

4. Архитектура на системот (Online фаза)

Online фазата е имплементирана преку микросервисна архитектура користејќи Docker контејнери.

- **Apache Kafka & Zookeeper**: Служат како пораки-брокер (message broker). Користени се два топици:
  - `health_data`: За сурови податоци од пациентите.
  - `health_data_predicted`: За збогатени податоци со предвидувањето од моделот.
- **Kafka Producer (`producer.py`)**: Скрипта која го чита `online.csv` ред по ред и ги испраќа податоците (без класата `Diabetes_012`) во JSON формат до Kafka.
- **Spark Structured Streaming**: Апликација која го вчитува зачуваниот модел, се претплатува на `health_data`, врши предвидувања во реално време и ги испраќа назад во вториот топик.
- **Kafka Consumer (`consumer.py`)**: Скрипта која ги презема предвидувањата од `health_data_predicted` и ги зачувува во `predictions_log.txt`.

---

5. Технички предизвици и решенија (macOS)

За време на имплементацијата на macOS со Apple Silicon, беа надминати следните проблеми:

- **Bus Error / Java Gateway Error**: Решено со зголемување на ресурсите во Docker Desktop (8GB RAM) и користење на готов `jupyter/pyspark-notebook` имиџ наместо сопствен Dockerfile.
- **Kafka Listeners**: Конфигурирани се две порти за Kafka:
  - `localhost:9092`: За надворешна комуникација (Mac терминал).
  - `kafka:29092`: За внатрешна комуникација (Spark во Docker).

---

6. Стартување на апликацијата

Процесот на извршување се одвива по следниот редослед:

1. **Подигнување на околината**: `docker-compose up -d`
2. **Креирање topics**:

   ```
   docker exec -it kafka kafka-topics --create --topic health_data --
   bootstrap-server localhost:9092

   docker exec -it kafka kafka-topics --create --topic
   health_data_predicted --bootstrap-server localhost:9092
   ```

3. **Стартување на Consumer**: `python3 consumer.py` (запишува во `predictions_log.txt`)
4. **Стартување на Spark Streaming**: Извршување на Notebook-от во Jupyter со претходно вчитани Kafka пакети.
5. **Стартување на Producer**: `python3 producer.py`

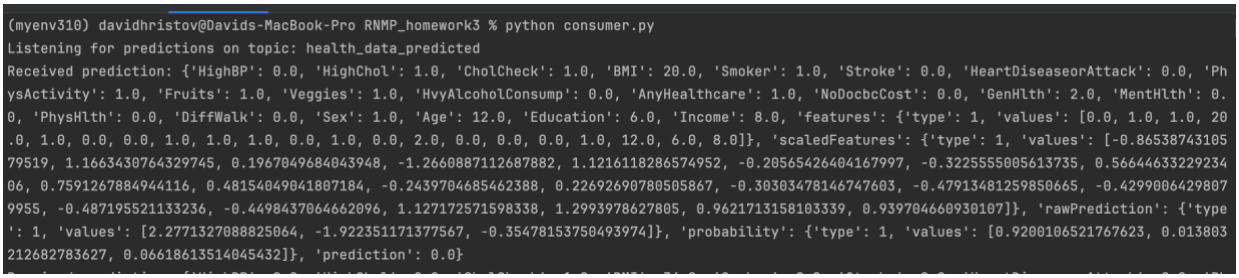

---

7. Резултати

Системот успешно ги процесира податоците во реално време. Крајниот резултат во `predictions_log.txt` содржи информации за пациентот заедно со предвидената вредност (`0.0` за здрави, `1.0/2.0` за дијабетес).

Примерок од излез:

Plaintext
```
Patient - Age: 12.0, BMI: 20.0, Prediction: 0.0
Patient - Age: 8.0, BMI: 34.0, Prediction: 0.0
Patient - Age: 12.0, BMI: 24.0, Prediction: 1.0
```

---

8. Заклучок

Успешно е демонстрирана интеграција помеѓу Spark MLlib и Spark Structured Streaming. Системот е скалабилен и овозможува брза дијагностика базирана на веќе тренирани историски податоци, што е од големо значење во медицинската информатика.

Изработил: Давид Христов **Датум:** Јануари, 2026